

LAPORAN PRAKTIKUM
KECERDASAN BUATAN

SIMPLE LINEAR REGRESSION & MULTIPLE
LINEAR REGRESSION



Maria Christin Gurning

42324058

D3 Teknologi Informasi

INSTITUT TEKNOLOGI DEL
FAKULTAS VOKASI

2026

Simple Linear Regression

In [1]

```
import pandas as pd
df = pd.read_csv('Salary_Data.csv')
print(df.head())
```


[1] ✓ 5.9s

	YearsExperience	Salary
0	1.1	39343.0
1	1.3	46205.0
2	1.5	37731.0
3	2.0	43525.0
4	2.2	39891.0

Penjelasan:

Kode ini mengimpor library pandas, membaca file Salary_Data.csv ke DataFrame df, lalu menampilkan 5 baris pertama dengan head(). Data terdiri dari dua kolom, YearsExperience (lama pengalaman kerja) dan Salary (gaji). Dari 5 baris pertama terlihat gaji cenderung naik seiring bertambahnya pengalaman.

In [2]



Penjelasan:

Variabel X berisi semua kolom kecuali kolom terakhir (YearsExperience) sebagai predictor. Variabel y berisi kolom terakhir (Salary) sebagai target yang diprediksi. Setelah itu, matplotlib menampilkan diagram sebar. Titik-titik merah membentuk pola naik yang hampir lurus, sehingga hubungan pengalaman dan gaji layak dimodelkan dengan regresi linear.

In [3]

```
#bagi dataset jadi train dan test 80:20
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random_state = 0)
✓ 0.0s
```

Penjelasan:

Dataset dibagi menjadi data latih (80%) dan data uji (20%) dengan train_test_split. Parameter random_state=0 membuat pembagian selalu sama setiap kali dijalankan, sehingga hasilnya konsisten. Data latih dipakai untuk membangun model, sedangkan data uji (6 data) dipakai untuk menguji model pada data yang belum pernah dilihat.

In [4]

```
# Fitting Simple Linear Regression to the Training set
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, y_train)
[7] ✓ 0.0s
```

LinearRegression ⓘ ⓘ

▼ Parameters

fit_intercept	True
copy_X	True
tol	1e-06
n_jobs	None
positive	False

▼ Fitted attributes

Name	Type	Value
coef_	ndarray[float64](1,)	[9312.58]
intercept_	float64	2.678e+04
n_features_in_	int	1
rank_	int64	np.int64(1)
singular_	ndarray[float64](1,)	[12.65]

Penjelasan:

Objek `LinearRegression()` dibuat lalu dilatih dengan `fit(X_train, y_train)`. Pada proses ini model mencari garis lurus yang paling sesuai dengan data latih. Hasilnya tersimpan pada atribut model: `coef_ = 9312.58` (kemiringan garis) dan `intercept_  $\approx$  26780` (titik potong sumbu y).

In [5]

```

a = regressor.intercept_
b = regressor.coef_[0]

print("Estimated model intercept, a:", a)
print("Estimated mode slope, b:", b)
print(f" $\hat{y} = \{a:.2f\} + \{b:.2f\}x$ ")

[9] ✓ 0.0s

... Estimated model intercept, a: 26780.09915062818
Estimated mode slope, b: 9312.575126729189
 $\hat{y} = 26780.10 + 9312.58x$ 
```

Penjelasan:

Intercept (a) = 26780.10 adalah perkiraan gaji ketika pengalaman 0 tahun. Slope (b) = 9312.58 berarti setiap tambahan 1 tahun pengalaman menaikkan gaji sekitar 9312.58. Persamaan regresinya adalah $\hat{y} = 26780.10 + 9312.58x$.

In [6]

```

# memprediksi hasil pada data uji (Test set) menggunakan model regresi yang telah
y_pred = regressor.predict(X_test)
y_pred

[6] ✓ 0.0s

... array([ 40748.96184072, 122699.62295594,  64961.65717022,  63099.14214487,
          115249.56285456, 107799.50275317])
```

Penjelasan:

Model memprediksi gaji untuk 6 data uji dengan `predict(X_test)`. Hasilnya adalah 40748.96; 122699.62; 64961.66; 63099.14; 115249.56; dan 107799.50. Nilai-nilai ini nanti dibandingkan dengan gaji sebenarnya (`y_test`) untuk menilai kualitas model.


In [7]

```
# Menghitung nilai R-Square, yang mengukur seberapa baik model regresi linear
# Semakin mendekati 1, semakin baik model
from sklearn.metrics import r2_score
score=r2_score(y_test,y_pred)
score
✓ 0.0s
0.988169515729126
```

Penjelasan:

Nilai R-Square (R^2) dihitung dengan `r2_score(y_test, y_pred)` dan hasilnya **0.9882**. Artinya model menjelaskan sekitar 98,8% variasi gaji pada data uji, dan nilai ini sangat dekat dengan 1, sehingga performa model sangat baik.


In [8]



Penjelasan:

Grafik ini memperlihatkan data latih (titik merah) dan garis regresi hasil model (garis biru). Titik-titik tersebar dekat di sekitar garis, artinya model cocok dengan pola data latih.

In [9]



Penjelasan:

Grafik ini menampilkan data uji (titik merah) dengan garis regresi dari model yang dilatih pada data latih. Sebagian besar titik uji sangat dekat dengan garis, hanya satu titik (sekitar 4 tahun pengalaman) yang agak di bawah garis. Ini menunjukkan model dapat memprediksi data baru dengan baik.

In [10]

```
df2 = pd.read_csv('multiple_linear_regression_dataset.csv')
print(df2.head())
```

✓ 0.0s

	age	experience	income
0	25	1	30450
1	30	3	35670
2	47	2	31580
3	32	5	40130
4	43	10	47830

Penjelasan:

File `multiple_linear_regression_dataset.csv` dibaca ke `df2` dan 5 baris pertamanya ditampilkan. Data punya tiga kolom: `age` (usia) dan `experience` (pengalaman) sebagai predictor, serta `income` (pendapatan) sebagai target. Karena predictor-nya lebih dari satu, kasus ini termasuk regresi linear berganda.

In [11]

```
X2 = df2.iloc[:, :-1]
y2 = df2.iloc[:, 2]
```

[15] ✓ 0.0s

Penjelasan:

`X2` berisi semua kolom kecuali yang terakhir, yaitu `age` dan `experience`. `y2` berisi kolom indeks 2, yaitu `income`, sebagai target.

In [12]

```
# Bagi dataset menjadi train dan test 80:20
X_train2, X_test2, y_train2, y_test2 = train_test_split(X2, y2, test_size = 0.2, random_state = 0)
```

[16] ✓ 0.0s

Penjelasan:

Data dibagi 80% latih dan 20% uji dengan `random_state=0`. Data ujinya berjumlah 4 sampel, sesuai dengan 4 nilai prediksi pada sel berikutnya.

In [13]

```
regressor = LinearRegression()
regressor.fit(X_train2, y_train2)
```

✓ 0.2s

LinearRegression ⓘ ?

▼ Parameters

fit_intercept	True
copy_X	True
tol	1e-06
n_jobs	None
positive	False

▼ Fitted attributes

Name	Type	Value
coef_	ndarray[float64](2,)	[-97.99, 2205.91]
feature_names_in_	ndarray[object](2,)	['age', 'experience']
intercept_	float64	3.095e+04
n_features_in_	int	2
rank_	int64	np.int64(2)
singular_	ndarray[float64](2,)	[43.61, 12.81]

Penjelasan:

Model `LinearRegression()` dilatih dengan `X_train2` dan `y_train2`. Karena ada dua predictor, `coef_` berisi dua nilai sesuai urutan fitur ['age', 'experience'], yaitu -97.99 dan 2205.91. Intercept-nya sekitar 30950 ($3.095e+04$).

In [14]

```
# Predicting the Test set results
y_pred2 = regressor.predict(X_test2)
print(y_pred2)
```

✓ 0.0s

```
[46487.25542968 34623.71312375 49379.11875301 38349.57565764]
```

Penjelasan:

Model memprediksi income untuk 4 data uji dan hasilnya adalah 46487.26; 34623.71; 49379.12; dan 38349.58. Nilai ini nanti dibandingkan dengan pendapatan sebenarnya.

In [15]

```
a_ = regressor.intercept_  
b1 = regressor.coef_[0]  
b2 = regressor.coef_[1]  
print("Estimated model intercept, a:", a_)  
print("Estimated model slope, b1:", b1)  
print("Estimated model slope, b2:", b2)  
print(f"ŷ = {a_:.2f} {b1:.2f}x1 + {b2:.2f}x2")
```

✓ 0.0s

Estimated model intercept, a: 30945.793141906892
Estimated model slope, b1: -97.99352917934205
Estimated model slope, b2: 2205.9086190738694
ŷ = 26780.10 -97.99x1 + 2205.91x2

Penjelasan:

Intercept (a) = 30945.79. Koefisien b1 (age) = -97.99, artinya setiap tambahan 1 tahun usia menurunkan pendapatan sekitar 97.99 dengan pengalaman dianggap tetap. Koefisien b2 (experience) = 2205.91, artinya setiap tambahan 1 tahun pengalaman menaikkan pendapatan sekitar 2205.91 dengan usia dianggap tetap. Persamaan yang benar adalah $\hat{y} = 30945.79 - 97.99x_1 + 2205.91x_2$. Pengalaman jauh lebih berpengaruh daripada usia.

In [16]

```
# Menghitung nilai R-Square, yang mengukur seberapa baik model regresi linear  
# Semakin mendekati 1, semakin baik model  
score2=r2_score(y_test2,y_pred2)  
score2
```

[20] ✓ 0.0s

... 0.8872690560355565

Penjelasan:

$R^2 = 0.8873$, artinya model menjelaskan sekitar 88,7% variasi pendapatan pada data uji, dan ini tergolong baik. Nilainya lebih rendah daripada regresi sederhana pada data gaji (0.9882). Data uji hanya 4 sampel, jadi angka ini bisa berubah cukup besar jika pembagian datanya berbeda.

Tugas Bagian 1 – Simple Linear Regression

In [1]

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error
```

✓ 0.0s

Penjelasan:

Sel ini mengimpor library yang dibutuhkan: numpy dan pandas untuk pengolahan data, matplotlib untuk grafik, train_test_split untuk membagi data, LinearRegression untuk model, serta r2_score, mean_absolute_error, dan mean_squared_error untuk evaluasi.

In [2]

```
PATH1 = "rounded_hours_student_scores.csv"
```

✓ 0.0s

Penjelasan:

Variabel PATH1 menyimpan nama file dataset, yaitu rounded_hours_student_scores.csv. File ini harus berada di folder yang sama dengan notebook, atau path lengkapnya ditulis.

In [3]

```
# 1. Baca data
df = pd.read_csv(PATH1)
print(df.head())
print(df.info())
print(df.describe())
print("Missing value:\n", df.isnull().sum())
```

✓ 0.3s

	Hours	Scores
0	1.1	41
1	1.2	40
2	1.4	38
3	1.5	39
4	1.6	36

<class 'pandas.DataFrame'>
RangeIndex: 60 entries, 0 to 59
Data columns (total 2 columns):
Column Non-Null Count Dtype

0 Hours 60 non-null float64
1 Scores 60 non-null int64
dtypes: float64(1), int64(1)
memory usage: 1.1 KB
None

	Hours	Scores
count	60.000000	60.000000
mean	5.150000	46.433333
std	2.402365	5.699737
min	1.100000	36.000000
25%	3.150000	41.000000
50%	5.150000	47.000000
75%	7.150000	50.000000
max	9.200000	65.000000

Missing value:
Hours 0
Scores 0
dtype: int64

Penjelasan:

Data dibaca dan diperiksa. Dataset berisi 60 baris dan 2 kolom: Hours (jam belajar, 1.1 sampai 9.2, rata-rata 5.15) dan Scores (nilai, 36 sampai 65, rata-rata 46.43). Tidak ada missing value, sehingga data siap dipakai tanpa pembersihan tambahan.

In [4]

```
# 2. Tentukan X (waktu belajar) dan y (score)
x_col = next((c for c in df.columns if "hour" in c.lower()), df.columns[0])
y_col = next((c for c in df.columns if "score" in c.lower()), df.columns[-1])
X = df[[x_col]].values
y = df[[y_col]].values
print(f"\nX = {x_col} | y = {y_col}")
print("Korelasi:", round(df[x_col].corr(df[y_col]), 4))
```

[49] ✓ 0.0s

...

X = Hours | y = Scores
Korelasi: 0.7984

Penjelasan:

Kolom Hours ditetapkan sebagai X dan Scores sebagai y. Korelasi keduanya **0.7984**, yaitu hubungan positif yang kuat: semakin lama belajar, semakin tinggi nilai cenderung naik.

In [5]



Penjelasan:

Diagram sebar menunjukkan tren naik antara jam belajar dan nilai. Sebaran titiknya lebih melebar dibanding data gaji pada praktikum, dan ada beberapa titik yang menyimpang, misalnya nilai 60 pada 7.4 jam dan nilai 65 pada 9.2 jam. Jadi hubungannya linear, tetapi ada faktor lain yang ikut memengaruhi nilai.

In [6]

```
# 4. Bagi data 80:20
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
✓ 0.0s
```

Penjelasan:

Data dibagi menjadi 80% data latih (48 data) dan 20% data uji (12 data). `random_state=42` menjaga agar pembagiannya tetap sama setiap kali dijalankan.

In [7]

```
# 5. Latih model
regressor = LinearRegression()
regressor.fit(X_train, y_train)
a = regressor.intercept_
b = regressor.coef_[0]
print(f"\nIntercept (a): {a:.4f}")
print(f"Slope (b)      : {b:.4f}")
print(f"Persamaan      : y_hat = {a:.2f} + {b:.2f}x")
✓ 0.0s
```

```
Intercept (a): 36.4610
Slope (b)      : 1.8742
Persamaan      : y_hat = 36.46 + 1.87x
```

Penjelasan:

Model dilatih dengan data latih. Intercept = 36.4610, artinya perkiraan nilai bila belajar 0 jam. Slope = 1.8742, artinya setiap tambahan 1 jam belajar menaikkan nilai sekitar 1.87 poin. Persamaan regresinya $\hat{y} = 36.46 + 1.87x$.

In [8]

```
# 6. Prediksi & evaluasi
y_pred = regressor.predict(X_test)
print("\nHasil prediksi data uji:")
print(pd.DataFrame({"Jam": X_test.ravel(), "Aktual": y_test, "Prediksi": y_pred.round(2)}))

r2 = r2_score(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
print(f"\nR2 (uji) : {r2:.4f}")
print(f"MAE      : {mae:.4f}")
print(f"RMSE      : {rmse:.4f}")
print(f"R2 (latih): {r2_score(y_train, regressor.predict(X_train)):.4f}")
```

✓ 0.0s

Hasil prediksi data uji:


	Jam	Aktual	Prediksi
0	1.1	41	38.52
1	1.8	40	39.83
2	6.0	50	47.71
3	7.3	51	50.14
4	2.9	40	41.90
5	8.5	53	52.39
6	5.6	43	46.96
7	7.7	52	50.89
8	2.7	49	41.52
9	8.9	55	53.14
10	7.4	60	50.33
11	8.0	50	51.45

R2 (uji) : 0.5810
MAE : 2.8187
RMSE : 3.9583
R2 (latih): 0.6316

Penjelasan:

Model memprediksi 12 data uji, lalu dievaluasi. Hasilnya: R^2 data uji = **0.5810**, MAE = **2.8187**, RMSE = **3.9583**, dan R^2 data latih = 0.6316. Model menjelaskan sekitar 58,1% variasi nilai (kategori sedang), dan rata-rata prediksi meleset sekitar 2.82 poin. RMSE lebih besar dari MAE karena ada beberapa kesalahan besar, misalnya 7.4 jam dengan nilai aktual 60 tetapi prediksi 50.33. R^2 latih dan uji berdekatan, jadi tidak terjadi overfitting.

In [9]



Penjelasan:

Grafik kiri menunjukkan data latih dan garis regresi, sedangkan grafik kanan menunjukkan data uji dengan garis yang sama. Garis mengikuti tren naik data, tetapi titik-titik tersebar cukup lebar di sekitarnya, yang menjelaskan R^2 yang hanya sedang. Beberapa titik uji berada jauh dari garis, yaitu (7.4 jam, 60), (2.7 jam, 49), dan (5.6 jam, 43).

In [10]

```
# 8. Contoh prediksi
for j in [2, 5, 8]:
    print(f"Belajar {j} jam -> prediksi score = {regressor.predict([[j]])[0]:.2f}")
```

✓ 0.0s

Belajar 2 jam -> prediksi score = 40.21
Belajar 5 jam -> prediksi score = 45.83
Belajar 8 jam -> prediksi score = 51.45

Penjelasan:

Model dipakai untuk memprediksi nilai pada jam belajar baru: 2 jam $\rightarrow$ 40.21, 5 jam $\rightarrow$ 45.83, dan 8 jam $\rightarrow$ 51.45. Ketiga nilai ini masih dalam rentang data (1.1–9.2 jam) sehingga cukup wajar.

Prediksi untuk jam belajar di luar rentang itu tidak dianjurkan karena model hanya dilatih pada rentang tersebut.

In [11]

```
# 9. Analisis singkat
print(f"""
ANALISIS:
- Korelasi (df[x_col].corr(df[y_col]):.3f) menunjukkan hubungan linear positif antara waktu belajar dan score.
- Setiap tambahan 1 jam belajar menaikkan score sekitar {b:.2f} poin.
- R2 = {r2:.3f}: model menjelaskan {r2*100:.1f}% variasi score; sisanya dipengaruhi faktor lain.
- Rata-rata prediksi meleset sekitar {mae:.2f} poin (MAE).
""")
✓ 0.0s
```

```
ANALISIS:
- Korelasi 0.798 menunjukkan hubungan linear positif antara waktu belajar dan score.
- Setiap tambahan 1 jam belajar menaikkan score sekitar 1.87 poin.
- R2 = 0.581: model menjelaskan 58.1% variasi score; sisanya dipengaruhi faktor lain.
- Rata-rata prediksi meleset sekitar 2.82 poin (MAE).
```

Penjelasan:

Sel ini mencetak ringkasan analisis. Korelasi 0.798 menunjukkan hubungan linear positif yang kuat antara waktu belajar dan nilai. Setiap tambahan 1 jam belajar menaikkan nilai sekitar 1.87 poin. $R^2 = 0.581$, artinya model menjelaskan 58,1% variasi nilai dan sisanya dipengaruhi faktor lain seperti kemampuan awal atau kualitas belajar. MAE 2.82 berarti rata-rata prediksi meleset sekitar 2.82 poin.

Tugas Bagian 2 – Multiple Linear Regression

In [1]

```
PATH2 = "Marketing_Data.csv"
✓ 0.0s
```

Penjelasan:

Variabel PATH2 menyimpan nama file dataset, yaitu Marketing_Data.csv.

In [2]

```
# 1. Baca data
df2 = pd.read_csv(PATH2)
df2 = df2.loc[:, ~df2.columns.str.contains("^Unnamed")] # buang kolom indeks bila ada
print(df2.head())
print(df2.info())
print(df2.describe())
print("Missing value:\n", df2.isnull().sum())
```

✓ 0.0s

	youtube	facebook	newspaper	sales
0	84.72	19.20	48.96	12.60
1	351.48	33.96	51.84	25.68
2	135.48	20.88	46.32	14.28
3	116.64	1.80	36.00	11.52
4	318.72	24.00	0.36	20.88

```
<class 'pandas.DataFrame'>
RangeIndex: 171 entries, 0 to 170
Data columns (total 4 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   youtube     171 non-null    float64
1   facebook    171 non-null    float64
2   newspaper   171 non-null    float64
3   sales       171 non-null    float64
dtypes: float64(4)
memory usage: 5.5 KB
None
```

	youtube	facebook	newspaper	sales
count	171.000000	171.000000	171.000000	171.000000
mean	178.021053	27.671579	35.240000	16.922807
std	102.449597	17.913532	24.902918	6.314608
min	0.840000	0.000000	0.360000	1.920000
25%	91.080000	11.700000	13.740000	12.540000
50%	179.760000	26.760000	31.000000	15.480000
...				
facebook	0			
newspaper	0			
sales	0			
dtype:	int64			

Penjelasan:

Data dibaca dan kolom indeks otomatis (Unnamed) dibuang bila ada. Dataset berisi 171 baris dan 4 kolom bertipe angka: youtube, facebook, newspaper (anggaran iklan), dan sales (penjualan). Rata-rata sales = 16.92 dan tidak ada missing value.

In [3]

```
# 2. Tentukan X (youtube, facebook, newspaper) dan y (sales)
y_col2 = next((c for c in df2.columns if "sales" in c.lower()), df2.columns[-1])
feat = [c for c in df2.columns if c != y_col2]
X2 = df2[feat]
y2 = df2[y_col2]
print("\nFitur:", feat, "| Target:", y_col2)
print("\nKorelasi:\n", df2.corr().round(3))
```

✓ 0.0s

Fitur: ['youtube', 'facebook', 'newspaper'] | Target: sales


Korelasi:

	youtube	facebook	newspaper	sales
youtube	1.000	0.087	0.111	0.782
facebook	0.087	1.000	0.293	0.603
newspaper	0.111	0.293	1.000	0.255
sales	0.782	0.603	0.255	1.000

Penjelasan:

youtube, facebook, dan newspaper ditetapkan sebagai predictor, dan sales sebagai target. Korelasi dengan sales: youtube **0.782** (kuat), facebook **0.603** (sedang-kuat), newspaper **0.255** (lemah). Korelasi antar predictor rendah (paling tinggi 0.293), sehingga tidak ada indikasi multikolinearitas yang serius.

In [4]



Penjelasan:

Ada tiga diagram sebar, satu per media. YouTube menunjukkan tren naik yang paling jelas. Facebook juga naik tetapi lebih menyebar. Newspaper hampir tidak membentuk pola, yang sejalan dengan korelasinya yang lemah.

In [5]

```
# 4. Bagi data 80:20
X_train2, X_test2, y_train2, y_test2 = train_test_split(X2, y2, test_size=0.2, random_state=42)
✓ 0.0s
```

Penjelasan:

Data dibagi 80% latih (136 data) dan 20% uji (35 data) dengan `random_state=42`.

In [6]

```
# 5. Latih model
regressor2 = LinearRegression()
regressor2.fit(X_train2, y_train2)
a2 = regressor2.intercept_
print(f"Intercept (a): {a2:.4f}")
for k, v in zip(feats, regressor2.coef_):
    print(f"Koefisien {k}: {v:.4f}")
persamaan = f"y_hat = {a2:.4f} " + " ".join(f"{'+' if v >= 0 else '-'} {abs(v):.4f}*{k}" for k, v in zip(feats, regressor2.coef_))
print("Persamaan:", persamaan)
✓ 0.0s

Intercept (a): 3.7030
Koefisien youtube: 0.0442
Koefisien facebook: 0.1945
Koefisien newspaper: -0.0000
Persamaan: y_hat = 3.7030 + 0.0442*youtube + 0.1945*facebook - 0.0000*newspaper
```

Penjelasan:

Model dilatih dengan tiga predictor. Intercept = 3.7030. Koefisien youtube = 0.0442 dan facebook = 0.1945, keduanya positif, artinya kenaikan anggaran media tersebut diikuti kenaikan sales dengan media lain dianggap tetap. Koefisien newspaper ≈ 0 , jadi hampir tidak berpengaruh. Persamaannya $\hat{y} = 3.7030 + 0.0442 \cdot \text{youtube} + 0.1945 \cdot \text{facebook} + 0.0000 \cdot \text{newspaper}$.

In [7]

```
# 6. Prediksi & evaluasi
y_pred2 = regressor2.predict(X_test2)
r2_2 = r2_score(y_test2, y_pred2)
mae2 = mean_absolute_error(y_test2, y_pred2)
rmse2 = np.sqrt(mean_squared_error(y_test2, y_pred2))
n, p = len(y_test2), X_test2.shape[1]
adj = 1 - (1 - r2_2) * (n - 1) / (n - p - 1)
print(f"\nR2 (uji) : {r2_2:.4f}")
print(f"Adj. R2 : {adj:.4f}")
print(f"MAE : {mae2:.4f}")
print(f"RMSE : {rmse2:.4f}")
print(f"R2 (latih): {r2_score(y_train2, regressor2.predict(X_train2)):.4f}")
```


✓ 0.0s

```
R2 (uji) : 0.8729
Adj. R2 : 0.8606
MAE : 1.4034
RMSE : 2.3615
R2 (latih): 0.9075
```

Penjelasan:

Hasil evaluasi pada data uji: $R^2 = 0.8729$, Adjusted $R^2 = 0.8606$, MAE = **1.4034**, dan RMSE = **2.3615**. Model menjelaskan sekitar 87,3% variasi sales dengan rata-rata kesalahan sekitar 1.40 satuan. R^2 latih (0.9075) dan uji berdekatan, jadi model generalisasi dengan baik. RMSE yang lebih besar dari MAE menandakan ada beberapa prediksi dengan kesalahan besar.

In [8]



Penjelasan:

Grafik kiri (aktual vs prediksi) menunjukkan titik-titik mengikuti garis putus-putus, artinya prediksi mendekati nilai sebenarnya. Pada grafik residual, sebagian besar residual tersebar acak di sekitar nol dengan rentang sekitar ± 3 . Ada satu titik yang sangat menyimpang (residual sekitar -11, aktual sekitar 2 tetapi diprediksi sekitar 13), dan titik ini yang membesarkan RMSE. Residual juga tampak sedikit membentuk pola melengkung, yang mengindikasikan hubungan tidak sepenuhnya linear.

In [9]

```
# 8. Pengaruh tiap fitur (koefisien terstandarisasi)
std_coef = pd.Series(regressor2.coef_, index=feat) * X_train2.std() / y_train2.std()
print("\nKoefisien terstandarisasi:\n", std_coef.round(4))

✓ 0.0s

Koefisien terstandarisasi:
youtube      0.7322
facebook     0.5606
newspaper    -0.0002
dtype: float64
```

Penjelasan:

Koefisien terstandarisasi membandingkan pengaruh tiap media pada skala yang sama: youtube **0.7322**, facebook **0.5606**, newspaper **-0.0002**. YouTube adalah media paling berpengaruh terhadap sales, diikuti facebook, sedangkan newspaper hampir tidak berpengaruh.

In [10]

```
# 9. Analisis singkat
kuat, lemah = std_coef.abs().idxmax(), std_coef.abs().idxmin()
print(f"""
ANALISIS:
- Persamaan: {persamaan}
- R2 = {r2_2:.3f}: gabungan {' '.join(feat)} menjelaskan {r2_2*100:.1f}% variasi sales.
- Rata-rata prediksi meleset sekitar {mae2:.2f} satuan (MAE).
- Media paling berpengaruh: {kuat}; paling lemah: {lemah}.
- Koefisien positif berarti kenaikan anggaran media itu diikuti kenaikan sales (media lain dianggap tetap).
""")

[46] ✓ 0.0s

...

ANALISIS:
- Persamaan: y_hat = 3.7030 + 0.0442*youtube + 0.1945*facebook - 0.0000*newspaper
- R2 = 0.873: gabungan youtube, facebook, newspaper menjelaskan 87.3% variasi sales.
- Rata-rata prediksi meleset sekitar 1.40 satuan (MAE).
- Media paling berpengaruh: youtube; paling lemah: newspaper.
- Koefisien positif berarti kenaikan anggaran media itu diikuti kenaikan sales (media lain dianggap tetap).
```

Penjelasan:

Ringkasan analisis: persamaan regresi adalah $y = 3.7030 + 0.0442 \cdot \text{youtube} + 0.1945 \cdot \text{facebook} - 0.0000 \cdot \text{newspaper}$. $R^2 = 0.873$, artinya ketiga media menjelaskan 87,3% variasi sales. MAE 1.40 berarti rata-rata prediksi meleset sekitar 1.40 satuan. Media paling berpengaruh adalah youtube dan yang paling lemah newspaper. Secara praktis, anggaran iklan sebaiknya difokuskan ke youtube dan facebook.